

Contents

1. Proje Konusunun Önemi ve Özgün Değeri.....	2
Özgün Değer	2
2. Projenin Amacı ve Hedefi	2
3. Projenin İş-Zaman Çizelgesi	3
4. Projede Kullanılacak Yöntem, Donanımlar ve Yazılımlar ile İlgili Bilgiler.....	4
4.1 Donanımlar	4
4.2 Yazılımlar	4
5. Projenin Yapım Aşamaları	5
❖ Ülker, M., & Özer, A. B. (2025).	5
9, 10 ve 11 Haftalar:.....	6
12, 13 ve 14. Haftalar:.....	7
6. Kaynakça	9

1. Proje Konusunun Önemi ve Özgün Değeri

Transformatör Modelleri Kullanarak İngilizce Hikâye Metinlerini Otomatik Özetleyen Uygulama Nedir?

Günümüzde dijital veri hacminin eksponansiyel artışı, uzun metinlerin kısa sürede analiz edilmesini zorlaştırmaktadır. Doğal Dil İşleme literatüründeki mevcut metin özetleme çalışmaları genellikle haber metinleri, kısa makaleler veya akademik dokümanlar üzerine yoğunlaşmakta; hikâye gibi edebi metinler görece arka planda kalmaktadır. Hikâye metinleri; karmaşık olay örgüleri, karakter dinamikleri, zaman çizelgesi ve uzun bağlam pencereleri içermesi sebebiyle, standart özetleme yaklaşımlarının ve mevcut dil modellerinin girdi sınırlarının yetersiz kaldığı bir problem alanıdır. Uzun metinleri doğrudan modellere beslemek, olay örgüsünün kaybolmasına veya yapay zeka halüsinasyonlarına yol açmaktadır.


Bu proje kapsamında, bu kısıtlamaları aşmak amacıyla transformatör mimarisine dayalı uçtan uca, hibrit bir otomatik özetleme modeli eğitilerek bir özetleme uygulaması geliştirilmiştir.

Özgün Değer

Bu projenin özgünlüğü, kullanılacak olan veri kümesi ve ince ayarlar sayesinde, hikâye kitaplarından seçilen verilerden oluşturularak modelin doğrudan bu alana özgü metinlerle eğitilmesini sağlamaktadır. Bu durum, genel amaçlı önceden eğitilmiş modellerin hikâye metinlerinde yaşadığı performans düşüşünü azaltmayı amaçlayan ayrıca bu tarz modellerin yaşadığı yetersiz token sorununa karşı çözüm üretmeye çalışan özgün bir yaklaşımdır.

2. Projenin Amacı ve Hedefi

Bu proje kapsamında, İngilizce hikâye metinlerinin özetlenmesindeki mevcut kısıtlamaları aşmak amacıyla transformatör mimarisine dayalı uçtan uca ve hibrit bir otomatik özetleme sistemi geliştirilmesi amaçlanmıştır. Bu doğrultuda öncelikle; uzun hikâye metinlerini analiz ederek metnin baş, orta ve son bölümlerinden anlamlı fragmanlar çıkaran bir ön işleme hattının kurulması, DistilBERT tabanlı Varlık İsmi Tanıma ile ana karakterlerin ve yerlerin tespit edilmesi ve KeyBERT ile TF-IDF algoritmaları entegre edilerek kritik anahtar kelimelerin elde edilerek çıkarılan bu üst verilerin ve kronolojik fragmanların, BART modeline beslenmesi sağlanmıştır. Nihai olarak, uygulanan ince ayar süreçleri ve optimize edilmiş çıkarım parametreleri sayesinde modelin halüsinasyon üretme eğiliminin engellendiği, hikâyenin kronolojik bütünlüğüne sadık ve insan editör kalitesine yakın tutarlı özetler üreten yenilikçi bir sistem mimarisinin ortaya konması amaçlanmaktadır.



Şekil 1 Projede Kullanılan Sistem

3. Projenin İş-Zaman Çizelgesi

İş-Zaman Çizelgesi

İP. No.	İş Paketlerinin Adı ve Hedefleri	Zaman Aralığı (Haftalık)	Başarı Ölçütü
1	Literatür taraması ve problem tanımının yapılması. Hikâye kitapları için metin özetleme, transformatör tabanlı modeller ve mevcut çalışmaların incelenmesi.	1.ve 2. haftalar	Proje kapsamının netleştirilmesi ve ilgili akademik kaynakların belirlenmesi.
2	Proje sunumunun hazırlanması ve yapılması. Transformatör mimarileri, çalışma prensipleri ve proje detaylarının aktarılması.	3, 4 ve 5. haftalar	Kapsamlı bir akademik sunumun başarıyla tamamlanması ve geri bildirimlerin alınması.
3	Veri kümesinin hazırlanması.	6. hafta	Veri kümesinin oluşturulması ve ön işleme aşamalarının tamamlanması.
4	Anahtar bilgi çıkarımı ve varlık ismi tanıma işlemleri. Metindeki önemli kelime, ifade ve karakterlerin belirlenmesi.	7. ve 8. haftalar	Anahtar bilgiler ve varlık isimleri belirlenmiş, zenginleştirilmiş metinlerin elde edilmesi.
5	Transformatör tabanlı özetleme modelinin kurulması ve eğitilmesi. Seçilen modelin veri kümesi üzerinde eğitilmesi ve ince ayarlarının yapılması.	9, 10, ve 11. haftalar	Hikâye metinlerinden otomatik özet üretebilen çalışır bir modelin elde edilmesi.
6	Model performansının değerlendirilmesi. ROUGE metrikleri ile modelin test edilmesi ve sonuçların analiz edilmesi. Elde edilen bulguların değerlendirilmesi ve proje raporunun tamamlanması.	12, 13 ve 14. haftalar	Model performansının ölçülmesi ve kabul edilebilir başarı seviyesine ulaşılması ve bitirme proje raporunun tamamlanarak teslim edilmesi.

4. Projede Kullanılacak Yöntem, Donanımlar ve Yazılımlar ile İlgili Bilgiler

Bu proje kapsamında, hikâye kitaplarından otomatik özet üretimi amacıyla doğal dil işleme ve derin öğrenme tabanlı yöntemler kullanılacaktır. Proje, metin önişleme, anahtar bilgi çıkarımı, transformatör tabanlı model eğitimi ve değerlendirme aşamalarından oluşmaktadır.

4.1 Donanımlar

Proje, yazılım tabanlı bir çalışma olduğundan özel bir donanım gereksinimi bulunmamaktadır. Model eğitimi ve test aşamaları için: En az 16 GB RAM'e sahip bir kişisel bilgisayar. Gerekli olması durumunda GPU destekli sistemler veya bulut tabanlı çalışma ortamları kullanılacaktır.

4.2 Yazılımlar

Projede izlenecek temel yöntem, soyutlamalı metin özetleme yaklaşımıdır. Bu yaklaşımda, kaynak metindeki cümleler doğrudan seçilmek yerine, metnin anlamı öğrenilerek yeni cümleler oluşturulmaktadır. Bu kapsamda kullanılacak yöntemler aşağıda özetlenmiştir:

- **Metin Önişleme:**
Hikâye metinleri üzerinde durak kelimelerin kaldırılması, noktalama işaretlerinin temizlenmesi ve metnin modele uygun formata dönüştürülmesi işlemleri gerçekleştirilecektir.
- **Anahtar Bilgi Çıkarımı:**
Metnin temel içeriğini temsil eden kelime ve ifadelerin belirlenmesi amacıyla:
 - TF-IDF
 - Transformatör tabanlı anahtar kelime çıkarım yöntemi kullanılacaktır.
- **Varlık İsmi Tanıma (NER):**
Hikâye metinlerindeki kişi, yer ve organizasyon isimlerinin belirlenmesi amacıyla transformatör tabanlı NER modelleri kullanılacaktır. Bu sayede karakterler ve olay mekânları özetlerde korunacaktır.
- **Transformatör Tabanlı Özetleme Modeli:**
Anahtar bilgiler ve varlık isimleri ile zenginleştirilmiş metinler, transformatör tabanlı bir özetleme modeline girdi olarak verilecektir. Model, metindeki anlamsal ilişkileri öğrenerek hikâyenin ana temasını yansıtan özetler üretecektir.
- **Model Eğitimi ve Değerlendirme:**
Model performansı ROUGE-1, ROUGE-2 ve ROUGE-L gibi metrikler kullanılarak değerlendirilecektir. Elde edilen sonuçlar literatürdeki temel özetleme modelleri ile karşılaştırılacaktır.

Proje geliştirme sürecinde aşağıdaki yazılımlar ve kütüphaneler kullanılacaktır:

Python, PyTorch veya TensorFlow, Hugging Face Transformers, NLTK / spaCy, Scikit-learn

5. Projenin Yapım Aşamaları

1. ve 2. Hafta: Literatür taraması yapılarak modeller arasındaki farklar incelendi ve veri kümesi nasıl hazırlanır araştırıldı. Yararlandığımız kaynaklar şunlardır:

- ❖ Long document summarization using page specific target text alignment and distilling page importance [Pushpa Devi](#), [Ayush Agrawal](#), [Ashutosh Dubey](#), [C. Ravindranath Chowdary](#)
- ❖ **Vaswani, A., et al. (2017).**
Attention is all you need.
<https://arxiv.org/abs/1706.03762>
- ❖ From Lemmas to Dependencies: What Signals Drive Light Verbs Classification?
[Sercan Karakas](#), [Yusuf Şimşek](#)
- ❖ **Long Document Summarization in a Low Resource Setting using Pretrained Language Models** [Ahsaas Bajaj](#), [Pavitra Dangati](#), [Kalpesh Krishna](#), [Pradhiksha Ashok Kumar](#), [Rheeya Uppaal](#), [Bradford Windsor](#), [Eliot Brenner](#), [Dominic Dotterer](#), [Rajarshi Das](#), [Andrew McCallum](#)
- ❖ <http://www.kemik.yildiz.edu.tr/>
- ❖ [Ülker, M., & Özer, A. B. \(2025\).](#)
Hikâye kitapları için transformatör tabanlı bir özetleme modeli.
<https://dergipark.org.tr/pub/fumbd/issue/88821/1599232>

3. , 4. Ve 5 Haftalar: Transformer mimarisi araştırılarak, mimari hakkında sunum hazırlanıp geri bildirim alındı

Sunumu hazırlarken kullanılan kaynaklar:

- 1) <https://erdem.pl/2021/05/understanding-positional-encoding-in-transformers>
- 2) <https://medium.com/machine-learning-t%C3%BCrkiye/attention-mekanizmasi-6d3566c0518e>
- 3) <https://tr.linkedin.com/pulse/transformer-modelleri-ve-attention-mekanizmas%C4%B1-ugur-akdogan-gevyf>
- 4) <https://cbarkinozer.medium.com/transformat%C3%B6rler-t%C3%BCm-i%C3%99htiyac%C4%B1n%C4%B1z-olan-dikkat-ee4ff66723b1>
- 5) <https://medium.com/@rabiaedayilmaz/attention-i%C3%99htiyac%C4%B1n-olan-tek-%C5%9Fey-adam%C4%B1m-e7e57635f050>
- 6) <https://medium.com/@batincangurbuz/dikkat-a%C4%B1n%C4%B1-attention-network-an-592240340768>
- 7) [https://en.wikipedia.org/wiki/Transformer_\(deep_learning\)](https://en.wikipedia.org/wiki/Transformer_(deep_learning))
- 8) <https://www.komtas.com/glossary/attention-mechanism-nedir>
- 9) <https://senemaktas.medium.com/n%C3%B6ral-makine-%C3%A7eviri-modelini-g%C3%B6rselle%C5%9Firme-seq2seq-modelinin-attention-mekanizmas%C4%B1-b12581b5a1df>
- 10) <https://apxml.com/courses/introduction-to-transformer-models/chapter-2-self-attention-multi-head-attention/query-key-value-vectors>
- 11) <https://lih-verma.medium.com/query-key-and-value-in-attention-mechanism-3c3c6a2d4085>
- 12) <https://epichka.com/blog/2023/qkv-transformer/>
- 13) <https://www.geeksforgeeks.org/nlp/word-embeddings-in-nlp/>
- 14) <https://medium.com/bili%C5%9Fim-hareketi/word-embedding-teknikleri-word2vec-nedir-tf-idf-nedir-e2f826dd9178>
- 15) <https://medium.com/thedeephub/all-you-need-to-know-about-tokenization-in-llms-7a801302cf54>

- 16) <https://www.youtube.com/watch?v=1biZfFLPRSY>
- 17) <https://www.geeksforgeeks.org/machine-learning/getting-started-with-transformers/>
- 18) <https://medium.com/machine-learning-t%C3%BCrkiye/transformer-encoder-yap%C4%B1s%C4%B1-self-attention-c44564d0b74b>
- 19) <https://www.youtube.com/watch?v=IZeaEqixmjY>
- 20) <https://erdem.pl/2021/05/understanding-positional-encoding-in-transformers>
- 21) <https://huggingface.co/blog/encoder-decoder>
- 22) <https://medium.com/machine-learning-t%C3%BCrkiye/transformer-encoder-yap%C4%B1s%C4%B1-self-attention-c44564d0b74b>
- 23) <https://molgorithm.medium.com/what-is-add-norm-as-soon-as-possible-178fc0836381>

6. Hafta: <https://huggingface.co/datasets/kmfoda/booksum> booksum veri setindeki gerekli yerler kullanıldı ve ön işleme yapıldı.

Dataset	# Docs.	Coverage	Density	Comp. Ratio	# Tokens	
					Source	Summary
Arxiv/PubMed	346,187	0.87	3.94	31.17	5179.22	257.44
BigPatent	1,341,306	0.86	2.38	36.84	3629.04	116.66
CNN/DM	311,971	0.85	3.47	14.89	803.67	59.72
Newsroom	1,212,739	0.83	9.51	43.64	799.32	31.18
XSum	226,677	0.66	1.09	19.25	438.43	23.89
NovelChapters*	8,088	-	-	-	5,165	372
BOOKSUM Paragraph (ours)	146,532	0.50	0.92	6.47	159.55	40.59
BOOKSUM Chapter (ours)	12,630	0.78	1.69	15.97	5101.88	505.42
BOOKSUM Full (ours)	405	0.89	1.83	126.22	112885.15	1167.20

Şekil 2 BOOKSUM veri seti özellikleri ve diğer popüler metin özetleme veri kümeleriyle karşılaştırılma tablosu

7 ve 8. Haftalar: Projenin iş paketleri doğrultusunda anahtar bilgi çıkarımı ve varlık ismi tanıma (NER) işlemleri gerçekleştirilerek modele verilecek girdi metinleri zenginleştirilmiştir. Bu kapsamda aşağıdaki adımlar koda dökülmüş ve test edilmiştir: Varlık İsmi Tanıma (NER): Hikâye akışındaki karakterlerin ve olay mekânlarının üretilecek özetlerde korunması amacıyla, Davlan/distilbert-base-multilingual-cased-ner-hrl modeli kullanılmış; metindeki kişi (PER), yer (LOC) ve organizasyon (ORG) isimleri orijinal metin üzerinden başarıyla tespit edilmiştir. Metin Ön işleme: Anahtar kelime çıkarım algoritmalarının başarısını artırmak için kaynak metindeki sayılar, noktalama işaretleri ve İngilizce durak kelimeler NLTK kütüphanesi yardımıyla temizlenerek metin modele uygun hale getirilmiştir. Anahtar Bilgi Çıkarımı: Temizlenmiş metin üzerinden, içeriği ve anlamsal ilişkileri en iyi yansıtan 3-gram ve 4-gram uzunluğundaki anahtar kelime öbekleri, transformatör tabanlı KeyBERT modeli kullanılarak çıkarılmıştır. Zenginleştirilmiş Metnin yani Belirteç Listesi Oluşturulması: Temel alınan akademik metodolojiye sadık kalınarak; metnin ilk paragrafı, NER ile çıkarılan varlık isimleri ve KeyBERT ile elde edilen anahtar kelimeler birleştirilmiştir. Transformatör tabanlı özetleme modeline girdi olarak verilecek nihai zenginleştirilmiş belirteç listesi elde edilmiştir.

9, 10 ve 11 Haftalar:

Dokuzuncu haftada, read_dataset ve HikayeDataset sınıfları aracılığıyla BookSum veri kümesi, "Sihirli Girdi" (Task Prefix) şablonuyla formüle edilerek sisteme tanımlanmış; 8GB VRAM limitlerine uygun olarak *Gradient Accumulation* (16) ve *Gradient Checkpointing* mekanizmaları kod içerisine gömülerek modelin eğitim kararlılığı sağlanmıştır. Onuncu haftada, modelin hiperparametreleri (LR=2e-5, AdamW, Warmup=200) üzerinde ince ayarlar yapılmış; eğitim sürecinde Early Stopping (patience=3) ile modelin ezberlemesi engellenerek en düşük doğrulama kaybını (best_val_loss) veren ağırlıklar (best_model) kaydedilmiştir. On birinci haftada ise, modelin çıkarım aşamasındaki halüsinasyon sorununu gidermek amacıyla model.generate fonksiyonu içerisinde length_penalty (1.0), temperature (0.3) ve no_repeat_ngram_size (3) gibi parametreler optimize edilerek modelin sadece sağlanan fragmanlar ve

anahtar kelimeler çerçevesinde tutarlı özetler üretmesi garantilenmiştir. Bu teknik süreçler sonucunda, tüm eğitim logları (egitim_log.txt) analiz edilmiş ve sistem, insan editör kalitesinde sonuçlar veren nihai formuna ulaştırılmıştır. Aşağıdaki tablolarda modeli oluştururken kullanılan hiperparametreler verilmiştir:

Hiperparametre / Ayar	Kullanılan Değer	Seçim Nedeni / Optimizasyon Amacı
BASE_MODEL_NAME	facebook/bart-large-cnn	Metin özetleme konusunda önceden eğitilmiş güçlü bir temel model olması.
MAX_INPUT	1024 Token	Baş, orta ve son fragmanların modele eksiksiz sığabilmesi için.
MAX_TARGET	512 Token	Olay örgüsünün kesilmeden daha detaylı özetlenebilmesi için.
Task Prefix (Sihirli Girdi)	Aktif	Kopuk paragrafları zaman sırasına göre birleştirme görevi verilmiştir.

Şekil 3 Model ve Veri Sınırları

Hiperparametre / Ayar	Kullanılan Değer	Seçim Nedeni / Optimizasyon Amacı
BATCH_SIZE	1	Kısıtlı GPU belleğinde OOM hatalarını önlemek için.
GRAD_ACCUM	16	Efektif batch size değerini 16'ya çıkarmak için.
USE_GRADIENT_CHECKPOINTING	1	GPU belleğinden tasarruf sağlamak için.
autocast (Mixed Precision)	True (FP16)	Bellek kullanımını azaltmak ve eğitimi hızlandırmak için.

Şekil 4 Hafıza ve Donanım Yönetimi

Hiperparametre / Ayar	Kullanılan Değer	Seçim Nedeni / Optimizasyon Amacı
EPOCHS	10	Modelin öğrenebilmesi için belirlenen maksimum eğitim turu.
Learning Rate	0.00002 (2e-5)	Kararlı fine-tuning sağlayan düşük öğrenme oranı.
WEIGHT_DECAY	0.01	Overfitting'i azaltmak amacıyla kullanılmıştır.
WARMUP_STEPS	200	Eğitim başlangıcındaki kararsızlığı azaltmak için.
EARLY_STOPPING_PATIENCE	3	Doğrulama başarımı durursa eğitimi erken sonlandırmak için.

Şekil 5 Eğitim Ayarları

Hiperparametre / Ayar	Kullanılan Değer	Seçim Nedeni / Optimizasyon Amacı
length_penalty	1.0	Gereksiz uzun çıktıları önlemek için.
temperature	0.3	Halüsinasyonları azaltmak ve daha deterministik sonuçlar elde etmek için.
do_sample	1	Daha doğal ve akıcı metin üretimi sağlamak için.
min_length	20	Kısa sahnelerde uydurma içerik oluşmasını engellemek için.
no_repeat_ngram_size	3	Tekrarlı cümleleri önlemek için.
num_beams	4	Daha kaliteli özet üretimi için birden fazla aday yol değerlendirmek amacıyla.

Şekil 6 Çıkarım Ayarları

12, 13 ve 14. Haftalar:

Eğitilen modelin performansının nicel metriklerle doğrulanması, hata analizlerinin tamamlanması ve projenin akademik çıktı olarak sonuçlandırılması sağlanmıştır. Rouge metriği (Recall Oriented Understudy of Gisting Evaluation), yazar tarafından oluşturulan özet ile model tarafından oluşturulan özetin

benzerliğini n-gram tabanlı olarak hesaplayan ölçüm yöntemidir . Yaygın olarak kullanılan üç değerlendirme metriği ROUGE-1, ROUGE-2 ve ROUGE-L'dir. En uzun ortak sıralı söz öbeğinin (LCS-Longest Common Subsequence) örtüşmesine dayalı hesaplama yöntemi Rouge-L özetleme modelinin performansını göstermek için diğerlerinin ölçüm yöntemlerinden daha fazla tercih edilmektedir. ROUGE-N'in hesaplaması verilmiştir:

$$ROUGE - N = \frac{\sum_{S \in \{referans \text{ özet}\}} \sum_{gram_n \in S} C_{eşleşme}(gram_n)}{\sum_{S \in \{referans\}} \sum_{gram_n \in S} C(gram_n)}$$

Denklem 1 Rouge N Hesabı

Burada, $gram_n$ n kelimeli sözcükleri, $C(gram_n)$ hedef özette bulunma sıklığı, $C_{eşleşme} gram_n$ kelime kümesi 'in hedef ve referans özette bulunma sıklığını ifade etmektedir.

$$Anma_{LCS} = \frac{LCS(X,Y)}{m}$$

$$Duyarluluk_{LCS} = \frac{LCS(X,Y)}{n}$$

$$F_{LCS} = \frac{2 * Anma_{LCS} * Duyarluluk_{LCS}}{(Anma_{LCS} + Duyarluluk_{LCS})}$$

Denklem 2 ROUGE-L Hesaplanması

Burada, X model tarafından üretilen özeti, Y orijinal özeti ifade etmektedir. LCS ise en uzun ortak alt diziyle çıkarılan kelime sayısını, m ise orijinal özetteki n gramların sayısı, n ise hedef özetteki n-gramların sayısını ifade etmektedir. ROUGE skoru, üretilen özet ile gerçek özetleri n-gramların ile örtüşmesine bağlı olarak karşılaştırmaktadır. Ancak, bu ölçüt tek başına üretilen özetlerin kalitesini kanıtlamak için yeterli değildir. Bu problemi ele almak amacıyla, üretilen özetler insan değerlendirme ölçütüne de tabi tutulmuştur. Fleiss'in kappa katsayısı, iki veya daha gönüllü arasında yapılan karşılaştırmalı anlaşmanın güvenilirliğini ölçmek için kullanılmaktadır. Fleiss'in kappa katsayısı, Denklem 3'de hesaplanmaktadır.

$$K = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$$

$$\bar{P} = \frac{1}{N} \sum_{i=1}^N P_i$$

$$\bar{P}_e = \sum_{j=1}^k \rho_j^2$$

$$\rho_j = \frac{1}{N * n} \sum_{i=1}^N n_{ij}$$

$$P_i = \frac{1}{n(n-1)} \sum_{i=1}^N n_{ij} (n_{ij} - 1)$$

Denklem 3 Fleiss'in kappa katsayısı

Burada N değerlendirilecek örneklem sayısını, n toplam değerlendirci sayısını, k değerlendirmede kullanılacak kategori sayısını ifade etmektedir. K değeri 0 ile 1 arasında bir değer olarak hesaplanmaktadır. Bu değer 1'e ne kadar yakınsa değerlendiriciler arasındaki tutarlılık o kadar fazladır.

Metrik	Bizim Modelimiz	Makale (Önerilen Model)
ROUGE-1	29.93	19.15
ROUGE-2	4.46	5.36
ROUGE-L	13.18	15.88

Şekil 7 Mödelin Rouge Skorları ve Referans Alınan Model ile Karşılaştırılması

Görseldeki tablo geliştirilen model ile referans alınan makaledeki önerilen modelin performanslarını karşılaştırmaktadır. Referans makaledeki model ROUGE-1 için 19.15 ROUGE-2 için 5.36 ve ROUGE-L için 15.88 değerlerini elde etmiştir. Geliştirilen yeni sistem ROUGE-1 skorunda 29.93 değerine ulaşarak tekil kelime tabanlı başarıda makaledeki modeli büyük bir farkla geride bırakmıştır. En uzun ortak sıralı söz öbeğinin örtüşmesine dayanan ROUGE-L metriğinde ise makaledeki modelin 15.88 skoru ile bizim 13.18 skorlu modelimizden daha başarılı olduğu görülmektedir. Benzer şekilde ardışık kelime eşleşmesini ölçen ROUGE-2 skorunda da makalede önerilen ve KeyBERT ile DistilBERT-NER gibi yöntemleri birleştiren mimarının hafif bir üstünlüğü bulunmaktadır. Bu sonuçlar yeni modelin hikaye içerisindeki temel kelimeleri ve kavramları yakalama konusunda çok daha yetenekli olduğunu ancak referans makaledeki sistemin cümle yapısını ve edebi bütünlüğü koruma açısından belirli bir yapısal avantaja sahip olduğunu açıkça ortaya koymaktadır.

6. Kaynakça

Hugging Face. (t.y.). *Text summarization task & transformer models documentation*. <https://huggingface.co/tasks/summarization>

Kryściński, W., Rajani, N., Agarwal, D., Xiong, C., & Radev, D. (2022). BOOKSUM: A collection of datasets for long-form narrative summarization. *arXiv preprint arXiv:2105.08209*.

Lin, C. Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Proceedings of the ACL-2004 Workshop* (s. 74-81). Association for Computational Linguistics. <https://aclanthology.org/W04-1013/>

Ülker, M., & Özer, A. B. (2025). Hikâye kitapları için transformatör tabanlı bir özetleme modeli. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 37(1), 1-10. <https://dergipark.org.tr/tr/pub/fumbd/issue/88821/1599232>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>

Zhang, J., Zhao, Y., Saleh, M., & Liu, P. J. (2020). PEGASUS: Pre-training with extracted gap-sentences for abstractive summarization. *International Conference on Machine Learning*, 11328-11339. <https://arxiv.org/abs/1912.08777>